浙江北学



课程名称: 操作系统原理与实践 题 目: Lab 3: RV64 虚拟内存管理 授课教师: 申文博 助 教: 王鹤翔、陈淦豪、许昊瑞 姓 名: 潘潇然 学 号: 3220106049 地 点: 32舍367

一、实验过程与步骤

1. 准备工程

• 在 defs.h 添加以下内容, 作为我们在本次实验中需要用到的宏

```
#define OPENSBI_SIZE (0x200000)

#define VM_START (0xffffffe000000000)

#define VM_END (0xffffffff000000000)

#define VM_SIZE (VM_END - VM_START)

#define PA2VA_OFFSET (VM_START - PHY_START)
```

- 关闭PIE, 保证实验正确性。在Makefile的 CF 中加入 -fno-pie
- 2. setup_vm 的实现
 - 首先我们需要将 0x800000000 开始的1GB区域进行两次映射, 其中先进行一次等值映射, 再进行一次加上 PV2VA_0FFSET 作为偏移量的映射, 使其映射到 direct mapping area

```
/* early_pgtbl: 用于 setup_vm 进行 1GiB 的映射 */
uint64_t early_pgtbl[512] __attribute__((__aligned__(0x1000)));
void setup_vm() {
    memset(early_pgtbl, 0x0, PGSIZE);
    // 设置 PA == VA 的等值映射
    // [53:28] = [55:30]
    uint64_t index = ((uint64_t)(PHY_START) >> 30) & 0x1ff; // 取[38:30]
    early_pgtbl[index] = (((PHY_START >> 30) & 0x3ffffff) << 28) | 0xf;

    // 设置 PA + PA2VA_OFFSET == VA 的映射
    index = ((uint64_t)(VM_START) >> 30) & 0x1ff;
    early_pgtbl[index] = (((PHY_START >> 30) & 0x3ffffff) << 28) | 0xf;
    printk("..setup_vm done!\n");
}
```

在SV39中,虚拟地址只有低39位有效,其中[38:30]表示 VPN[2],[29,21]表示 VPN[1],[20:12]表示 VPN[0]。物理地址中[55:30]表示 PPN[2],[29:21]表示 PPN[1],[20:12]表示 PPN[0]。在页表项中, [53:28]表示 PPN[2],[27:19]表示 PPN[1],[18:10]表示 PPN[0]

因此在等值映射中,将 PHY_START 的 [38,30] 取出来作为页表项的index,之后取出 其 [55:30]位,并将最后四位分别表示V,R,W,X的置为1即可

在 PA + PA2VA_OFFSET == VA 的映射中, 我们只需要将加上 PA2VA_OFFSET 的地址取出其 [38:30] 作为页表项的index即可, 其他均保持一致。

• 之后我们需要通过 relocate 函数完成对 satp 的设置

```
relocate:
    # set ra = ra + PA2VA_OFFSET
    # set sp = sp + PA2VA_OFFSET (If you have set the sp before)
   li t0, 0xffffffdf80000000
    add ra, ra, t0
    add sp, sp, t0
    # need a fence to ensure the new translations are in use
    sfence.vma zero, zero
    # set satp with early_pgtbl
   li t2, 8
    slli t2, t2, 60
   la t1, early_pgtbl
    srli t1, t1, 12
   or t1, t1, t2
   csrw satp, t1
    ret
```

这里我们首先通过伪指令 li 载入 PA2VA_OFFSET, 并将 ra 和 sp 分别加上此偏差。 之后在设置satp前我们需要先运行 sfence.vma 来保证新的页表项生效。在本次实验 中我们使用SV39, 因此我们将 [63:60] 设置为8。然后我们将页表项加载进来,将其 右移12位得到44位的PPN,将以上得到的两者取或即可得到satp的值。

• 之后我们在 head.S 的 _start 中的适当位置加入以上两个函数

```
_start:

la sp, boot_stack_top

jal setup_vm

jal relocate

jal mm_init
```

• 同时修改 mm init 函数,将结束地址调整为虚拟地址

```
void mm_init(void) {
   // kfreerange(_ekernel, (char *)PHY_END);
   kfreerange(_ekernel, (char *)(VM_START + PHY_SIZE));
   printk("...mm_init done!\n");
}
```

- 3. setup_vm_final 的实现:我们在调用 mm_init 完成内存管理初始化后,调用 setup_vm_final 需要完成对所有物理内存的映射,并设置正确的权限
 - create mapping 函数
 - 首先利用 va 和 sz 计算得到映射范围,当虚拟地址还没到映射末尾时,我们在每次循环结束加 PG SIZE 切换到下一页
 - 在每次循环,我们首先取出三级页表分别对应的 vpn
 - 首先对第一级页表,我们根据根页表基地址加上index得到对应的页表项。如果该页表项存在,即Valid Bit为1,我们就直接取出页表项,右移10位清零flag,之后左移12位到正确的位置,并记得需要加上 PA2VA_OFFSET 。若该页表不存在,则使用 kalloc() 获取一页,但注意到这里获取的是虚拟地址,需要我们减去 PA2VA_OFFSET 得到物理地址。之后我们对应地将其右移12位得到PPN,之后左移10位到正确的位置并加上 PA2VA_OFFSET ,最后将末位的Valid Bit置为1。对第二级页表,我们也采取类似的操作
 - 在第三级页表,我们直接将pte设置为pa的PPN并设置权限和Valid Bit即可

```
void create_mapping(uint64_t *pgtbl, uint64_t va, uint64_t pa, uint64_t sz,
                    uint64 t perm) {
  uint64 t va end = va + sz;
  uint64_t vpn2, vpn1, vpn0;
  while (va < va_end) {</pre>
    vpn2 = (va >> 30) \& 0x1FF;
    vpn1 = (va >> 21) \& 0x1FF;
    vpn0 = (va >> 12) \& 0x1FF;
    // 处理第一级页表
    uint64_t *pte2 = &pgtbl[vpn2];
    uint64_t *pgtbl_lvl1;
    if (!(*pte2 & PTE_V)) {
     pgtbl_lvl1 = (uint64_t *)(kalloc() - PA2VA_OFFSET);
     *pte2 = ((uint64_t)pgtbl_lvl1 >> 12 << 10) | PTE_V;
    pgtbl_lvl1 = (uint64_t *)(((*pte2 >> 10) << 12) + PA2VA_OFFSET);</pre>
    // 处理第二级页表
    uint64_t *pte1 = &pgtbl_lvl1[vpn1];
    uint64_t *pgtbl_lvl0;
```

```
if (!(*pte1 & PTE_V)) {
    pgtbl_lvl0 = (uint64_t *)(kalloc() - PA2VA_OFFSET);
    *pte1 = ((uint64_t)pgtbl_lvl0 >> 12 << 10) | PTE_V;
}

pgtbl_lvl0 = (uint64_t *)(((*pte1 >> 10) << 12) + PA2VA_OFFSET);

// 处理第三级页表
    uint64_t *pte0 = &pgtbl_lvl0[vpn0];
    *pte0 = (((uint64_t)pa & 0x003ffffffffffc00) >> 2) | perm;

// 下一个页面
    va += PGSIZE;
    pa += PGSIZE;
}
```

- setup_vm_final 函数
 - 首先我们需要定义 _stext , _srodata , _sdata , 并设置为 extern
 - 之后从 _stext 地址开始, 依次设置va, pa, sz并设置正确的权限位即可

```
/* swapper_pg_dir: kernel pagetable 根目录, 在 setup_vm_final 进行映射 */
uint64_t swapper_pg_dir[512] __attribute__((__aligned__(0x1000)));
extern char _stext[];
extern char _srodata[];
extern char _sdata[];
void setup_vm_final() {
  memset(swapper_pg_dir, 0x0, PGSIZE);
  // No OpenSBI mapping required
  // mapping kernel text X|-|R|V
  uint64_t va = _stext;
  uint64_t pa = (uint64_t)_stext - PA2VA_OFFSET;
  create_mapping((uint64_t *)swapper_pg_dir, va, pa,
                 (uint64_t)(_srodata - _stext), 11);
  // mapping kernel rodata -|-|R|V
  va += _srodata - _stext;
  pa += _srodata - _stext;
  create_mapping((uint64_t *)swapper_pg_dir, va, pa,
                 (uint64_t)(_sdata - _srodata), 3);
  // mapping other memory -|W|R|V
  va += _sdata - _srodata;
```

4. 编译测试: make run 后得到以下结果, 说明正确

```
..setup_vm done!
...mm_init done!
..setup_vm_final done
...task init done!
2024 ZJU Operating System
SET [PID = 1 PRIORITY = 7 COUNTER = 7]
SET [PID = 2 PRIORITY = 10 COUNTER = 10]
SET [PID = 3 PRIORITY = 4 COUNTER = 4]
SET [PID = 4 PRIORITY = 1 COUNTER = 1]
switch to [PID = 2 PRIORITY = 10 COUNTER = 10]
[PID = 2] is running. auto inc local var = 1
[PID = 2] is running. auto_inc_local_var = 2
[PID = 2] is running. auto_inc_local_var = 3
[PID = 2] is running. auto_inc_local_var = 4
[PID = 2] is running. auto_inc_local_var = 5
[PID = 2] is running. auto_inc_local_var = 6
[PID = 2] is running. auto_inc_local_var = 7
[PID = 2] is running. auto_inc_local_var = 8
[PID = 2] is running. auto_inc_local_var = 9
[PID = 2] is running. auto_inc_local_var = 10
switch to [PID = 1 PRIORITY = 7 COUNTER = 7]
[PID = 1] is running. auto_inc_local_var = 1
[PID = 1] is running. auto_inc_local_var = 2
[PID = 1] is running. auto_inc_local_var = 3
[PID = 1] is running. auto_inc_local_var = 4
[PID = 1] is running. auto_inc_local_var = 5
[PID = 1] is running. auto_inc_local_var = 6
```

```
[PID = 1] is running. auto_inc_local_var = 7

switch to [PID = 3 PRIORITY = 4 COUNTER = 4]
[PID = 3] is running. auto_inc_local_var = 1
[PID = 3] is running. auto_inc_local_var = 2
[PID = 3] is running. auto_inc_local_var = 3
[PID = 3] is running. auto_inc_local_var = 4

switch to [PID = 4 PRIORITY = 1 COUNTER = 1]
[PID = 4] is running. auto_inc_local_var = 1

SET [PID = 1 PRIORITY = 7 COUNTER = 7]
SET [PID = 2 PRIORITY = 10 COUNTER = 10]
SET [PID = 3 PRIORITY = 4 COUNTER = 4]
SET [PID = 4 PRIORITY = 1 COUNTER = 1]
```

二、思考题

- 1. 验证 .text , .rodata 段的属性是否成功设置, 给出截图。
- 我们将 main.c 修改成如下, 在 start_kernel 中加入输出 _stext 和 _srodata

```
extern char _stext[];
extern char _srodata[];

int start_kernel() {
    printk("2024");
    printk(" ZJU Operating System\n");
    printk("The value of _stext is: %lx\n", (uint64_t)(_stext));
    printk("The value of _srodata is: %lx\n", (uint64_t)(_srodata));

    test();
    return 0;
}
```

运行得到以下截图, 说明成功设置地址

```
Boot HART MEDELEG : 0x0000000000000509
..setup_vm done!
...mm_init done!
..setup_vm_final done
...task_init done!
2024 ZJU Operating System
The value of _stext is: ffffffe000200000
The value of _srodata is: ffffffe000203000
SET [PID = 1 PRIORITY = 7 COUNTER = 7]
```

• 之后再修改成以下, 验证读写属性

```
extern char _stext[];
extern char _srodata[];

int start_kernel() {
    printk("2024");
    printk(" ZJU Operating System\n");
    printk("The value of _stext is: %lx\n", (uint64_t)(*_stext));
    printk("The value of _srodata is: %lx\n", (uint64_t)(*_srodata));
    *_stext = 0x0;
    *_srodata = 0x1;

test();
    return 0;
}
```

运行得到以下内容,我们根据前两行输出得到 _stext 和 _srodata 可读,同时观察下两行 scause 为f,即15,查询特权级指令手册,我们知道首位为0代表是异常,同时15 对应的报错是 Store/AMO page fault ,由于可读取我们知道这时的page fault是由于不可写导致的。

```
Z024 ZJU Operating System
The value of _stext is: 17
The value of _srodata is: 2e
scause: f, sepc: ffffffe0002012d4
scause: f, sepc: ffffffe0002012d4
```

- 接下来我们需要验证这两个字段的可执行性。
 - _stext 段我们设置的是可执行,此段为代码段,通常用来存放程序执行代码,由 于我们的程序可以正常运行,因此说明此段可执行
 - _srodata 段对应存储的是只读数据,因此我们设置的是不可执行,为了验证这一段确实不可以执行,我们同样对 main.c 进行如下修改

```
int start_kernel() {
  printk("2024");
  printk(" ZJU Operating System\n");
  //  printk("The value of _stext is: %lx\n", (uint64_t)(*_stext));
  //  printk("The value of _srodata is: %lx\n", (uint64_t)(*_srodata));
  //  *_stext = 0x0;
  //  *_srodata = 0x1;
  asm volatile("call _srodata");
  test();
  return 0;
}
```

```
...setup_vm_final done
...task_init done!
2024 ZJU Operating System
scause: c, sepc: ffffffe000203000
```

scause 为 c, 即 12, 同样查阅特权级指令手册知道,代表 Instruction page fault ,说明PC错误,即执行地址错误,说明我们访问到了不可执行的部分,说明设置正确。

- 2. 为什么我们在 setup_vm 中需要做等值映射? 在 Linux 中,是不需要做等值映射的,请探索一下不在 setup_vm 中做等值映射的方法。你需要回答以下问题:
 - 1. 本次实验中如果不做等值映射,会出现什么问题,原因是什么;
 - 会出现page fault,如果不做等值映射,当我们在 relocate 中设置 satp 后,这之后的输入都会被当成虚拟地址转换成物理地址后执行。这时在 csrw 下一行的指令,由于其pc地址为上一条指令,即 csrw 指令的pc加4,仍然是物理地址,如果不做等值映射,访问这一页就会出现page fault,导致程序无法继续执行。
 - 原因:在启用分页机制之前,CPU 无法直接使用虚拟地址访问物理地址。因此,通过建立等值映射,可以使得虚拟地址空间的某一部分直接映射到相同的物理地址空间,使得可以找得到这部分物理地址。
 - 2. 简要分析 Linux v5.2.21 或之后的版本中的内核启动部分(直至 init/main.c 中 start_kernel 开始之前),特别是设置 satp 切换页表附近的逻辑;
 - 首先我们打开 arch/riscv/kernel/head.S, 在 _start 中, 首先进行了一些初始化操作, 如屏蔽所有中断、加载全局指针(GF)、禁用浮点单元、主处理器选择、清空 .bss 段、保存硬件线程等操作。
 - 之后,采用和我们在之前实验中类似的操作调用 setup_vm 和 relocate 设置虚拟内存,之后恢复栈指针和 tp ,最后启动内核。

```
/* Initialize page tables and relocate to virtual addresses */
    la sp, init_thread_union + THREAD_SIZE
    call setup_vm
    call relocate

/* Restore C environment */
    la tp, init_task
    sw zero, TASK_TI_CPU(tp)
    la sp, init_thread_union + THREAD_SIZE

/* Start the kernel */
    mv a0, s1
    call parse_dtb
    tail start_kernel
```

• 之后我们首先来分析 setup_vm , 见以下注释内容, 主要完成了偏移量的计算以及使用三级页表还是四级页表

```
asmlinkage void __init setup_vm(void)
{
   // 函数及变量定义
   extern char _start;
   uintptr_t i;
   uintptr t pa = (uintptr t) & start;
   pgprot_t prot = __pgprot(pgprot_val(PAGE_KERNEL) | _PAGE_EXEC); // 权限
   // 计算虚拟地址和物理地址的偏移
   va_pa_offset = PAGE_OFFSET - pa;
    pfn_base = PFN_DOWN(pa);
   /* Sanity check alignment and size */
   BUG ON((PAGE OFFSET % PGDIR SIZE) != 0);
   BUG ON((pa % (PAGE SIZE * PTRS PER PTE)) != 0);
    // 设置页表结构, 判断是否使用PMD折叠, 使用三级页表还是四级页表
#ifndef PAGETABLE PMD FOLDED
    trampoline_pg_dir[(PAGE_OFFSET >> PGDIR_SHIFT) % PTRS_PER_PGD] =
       pfn_pgd(PFN_DOWN((uintptr_t)trampoline_pmd),
            __pgprot(_PAGE_TABLE));
    trampoline_pmd[0] = pfn_pmd(PFN_DOWN(pa), prot);
   for (i = 0; i < (-PAGE OFFSET)/PGDIR SIZE; ++i) {
       size_t o = (PAGE_OFFSET >> PGDIR_SHIFT) % PTRS_PER_PGD + i;
       swapper_pg_dir[o] =
           pfn_pgd(PFN_DOWN((uintptr_t)swapper_pmd) + i,
               __pgprot(_PAGE_TABLE));
    for (i = 0; i < ARRAY_SIZE(swapper_pmd); i++)</pre>
       swapper_pmd[i] = pfn_pmd(PFN_DOWN(pa + i * PMD_SIZE), prot);
    swapper_pg_dir[(FIXADDR_START >> PGDIR_SHIFT) % PTRS_PER_PGD] =
       pfn_pgd(PFN_DOWN((uintptr_t)fixmap_pmd),
               __pgprot(_PAGE_TABLE));
    fixmap_pmd[(FIXADDR_START >> PMD_SHIFT) % PTRS_PER_PMD] =
       pfn_pmd(PFN_DOWN((uintptr_t)fixmap_pte),
               __pgprot(_PAGE_TABLE));
#else
    trampoline_pg_dir[(PAGE_OFFSET >> PGDIR_SHIFT) % PTRS_PER_PGD] =
       pfn_pgd(PFN_DOWN(pa), prot);
    for (i = 0; i < (-PAGE_OFFSET)/PGDIR_SIZE; ++i) {
       size_t o = (PAGE_OFFSET >> PGDIR_SHIFT) % PTRS_PER_PGD + i;
```

• 接下来我们分析 relocate 函数

```
relocate:
   /* Relocate return address */
   #计算虚拟地址与物理地址的偏移,以调整ra的值
   li a1, PAGE OFFSET
   la a0, _start
   sub a1, a1, a0
   add ra, ra, a1
   /* Point stvec to virtual address of intruction after satp write */
   #这里将stvec的地址从物理地址转换为虚拟地址,这一步很关键。这是因为Linux没有
进行等值映射。那么在我们通过设置satp启用MMU后,以下所有指令都会被当成虚拟地址传
入MMU转换成物理地址进行执行。但此时trap_handler的地址,以及satp的下一条指令还仍
然是物理地址, 就会出现page fault。这时, 为了触发page fault可以正确地进入
trap handler, 自然我们需要设置stvec
   la a0, 1f
   add a0, a0, a1
   csrw CSR_STVEC, a0
   /* Compute satp for kernel page tables, but don't load it yet */
   #计算swapper_pg_dir页表的虚拟地址,和实验中写的类似
   la a2, swapper_pg_dir
   srl a2, a2, PAGE_SHIFT
   li a1, SATP_MODE
   or a2, a2, a1
   /*
    * Load trampoline page directory, which will cause us to trap to
    * stvec if VA != PA, or simply fall through if VA == PA. We need a
    * full fence here because setup_vm() just wrote these PTEs and we need
    * to ensure the new translations are in use.
    */
    #设置线性页表并设置satp
   la a0, trampoline_pg_dir
```

```
srl a0, a0, PAGE_SHIFT
    or a0, a0, a1
    sfence.vma
    csrw CSR SATP, a0
.align 2
1:
    /* Set trap vector to spin forever to help debug */
    la a0, .Lsecondary_park
    csrw CSR_STVEC, a0
    /* Reload the global pointer */
.option push
.option norelax
    la gp, __global_pointer$
.option pop
    /*
    * Switch to kernel page tables. A full fence is necessary in order to
    * avoid using the trampoline translations, which are only correct for
     * the first superpage. Fetching the fence is guarnteed to work
     * because that first superpage is translated the same way.
    */
    csrw CSR SATP, a2
    sfence.vma
    ret
```

- 3. 回答 Linux 为什么可以不进行等值映射,它是如何在无等值映射的情况下让 pc 从物理地址跳到虚拟地址:
- Linux首先在 reloacte 中将 stvec 加上偏移量。
- 之后在执行设置完 satp 后的下一条指令,由于此时的地址仍然是物理地址,在传入MMU后无法找到对应的地址,就会产生page fault。这时候由于我们将 stvec 加上偏移量了,这时候我们就可以正常访问 trap_handler 。此时我们只需要在 trap_handler 内将 sepc 加上虚拟地址即可。这样我们跳出 trap_handler 程序后,就可以返回到正确的地址。
- 4. Linux v5.2.21 中的 trampoline_pg_dir 和 swapper_pg_dir 有什么区别,它们 分别是在哪里通过 satp 设为所使用的页表的;
- trampoline_pg_dir 是一个用于内核启动阶段的临时页表,通常用于处理内核启动时的虚拟地址映射。在这个阶段,内核可能还没有完全切换到常规的内核虚拟地址空间,因此需要一个简单的页表来支持早期的代码执行,允许内核在虚拟地址空间和物理地址空间之间做必要的切换。

设置:

```
#设置线性页表并设置satp
la a0, trampoline_pg_dir
srl a0, a0, PAGE_SHIFT
or a0, a0, a1
sfence.vma
csrw CSR_SATP, a0
```

swapper_pg_dir 是内核的主要页表,包含了内核虚拟地址空间的页表映射。swapper_pg_dir 被用于系统的正常运行阶段,在内核启动完成后,内核将切换到使用这个页表来管理内存映射。也就是我们所使用的三级页表

设置:

```
/* Compute satp for kernel page tables, but don't load it yet */
    #计算swapper_pg_dir页表的虚拟地址,和实验中写的类似
   la a2, swapper_pg_dir
   srl a2, a2, PAGE_SHIFT
   li a1, SATP MODE
   or a2, a2, a1
   . . .
.align 2
1:
.option push
.option norelax
   la gp, __global_pointer$
.option pop
   /*
    * Switch to kernel page tables. A full fence is necessary in order to
    * avoid using the trampoline translations, which are only correct for
    * the first superpage. Fetching the fence is guarnteed to work
    * because that first superpage is translated the same way.
    */
   csrw CSR_SATP, a2
    sfence.vma
    ret
```

- 5. 尝试修改你的 kernel, 使得其可以像 Linux 一样不需要等值映射。
 - 首先在 relocate 中设置 stvec 为我们新设置的 new traps

```
la a0, _new_traps
add a0, a0, t0
csrw stvec, a0
```

• 之后书写 _new_traps , 在函数中, 我们只需要将 sepc 加上虚拟地址和物理地址 之间的偏移量即可, 这样我们就可以返回到正确的地址了

```
.globl _new_traps
_new_traps:
   addi sp,sp,-8
   sd t0, 0(sp)

   csrr t0,sepc
   li t1,0xffffffdf80000000
   add t0,t0,t1
   csrw sepc,t0

   ld t0,0(sp)
   addi sp,sp,8
   sret
```

• 最后值得注意的是,由于我们只在第一次才需要跳转进 _new_traps , 我们需要在 head.S 中调用 relocate 后, 立即设置 stvec 为 trap_handler , 避免出错

```
jal setup_vm
jal relocate

# set stvec = _traps
la a0, _traps
csrw stvec, a0

jal mm_init
jal setup_vm_final
```

• 这样我们就可以正常运行了

```
Boot HART MEDELEG : 0x000000000000050509
..setup_vm done!
sepc:ffffffe0002000a4...mm_init done!
..setup_vm_final done
...task_init done!
2024 ZJU Operating System
[S] Supervisor Mode Timer Interrupt
SET [PID = 1 PRIORITY = 7 COUNTER = 7]
SET [PID = 2 PRIORITY = 10 COUNTER = 10]
SET [PID = 3 PRIORITY = 4 COUNTER = 4]
SET [PID = 4 PRIORITY = 1 COUNTER = 1]

switch to [PID = 2 PRIORITY = 10 COUNTER = 10]
[PID = 2] is running. auto_inc_local_var = 1
```